

Projekt-Dokumentation - DocumentManagementSystem

Architektur-Entscheidungen

Backend (.NET 8, **ASP.NET Core**)

- **.NET 8 & C#**: Moderne, performante Plattform mit guter Unterstützung für Web-APIs, Entity Framework und Docker. Team-Expertise vorhanden.
- **Code-First REST API**: Endpunkte werden im Team abgestimmt und direkt im Code definiert. Das ermöglicht schnelle Iteration und Anpassung.
- **Repository-Pattern & ORM (EF Core)**: Trennung von Business-Logik und Datenzugriff, bessere Testbarkeit und Wartbarkeit. PostgreSQL als DB wegen Stabilität und Open-Source.
- **Unit-Tests mit Mocking**: xUnit und Moq, produktive DB wird für Tests gemockt. So werden Seiteneffekte vermieden und die Funktionalität gesichert.
- **Containerisierung (docker-compose)**: Backend und Datenbank laufen als Container, Healthchecks und Umgebungsvariablen sind konfiguriert. Das Setup ist reproduzierbar und einfach zu deployen.

Frontend (React, Web-UI)


- **React mit modernen Komponenten**: Flexibel, weit verbreitet, unterstützt schnelle UI-Entwicklung. Tailwind und Lucide-Icons sorgen für ein modernes, konsistentes Design.
- **nginx als Webserver**: Leichtgewichtig, performant, weit verbreitet. Trennung von Backend und UI ermöglicht unabhängige Entwicklung und Deployment.
- **Kommunikation per REST**: Die UI kommuniziert per HTTP mit dem REST-Server, API-Requests werden per Proxy weitergeleitet. Klare Trennung der Verantwortlichkeiten.
- **docker-compose für UI**: Die UI läuft als eigener Container, Compose-File enthält jetzt drei Services (DB, Backend, UI). Modular und skalierbar.

UI-Konzept und Interaktionen (Sprint 2)

Das Interface des Dokumentenmanagement Systems bietet drei Kernfunktionen:


1. Upload

- **Dokument hochladen:** Drag & Drop oder Dateiauswahl, Metadaten (Titel, Beschreibung, Tags) werden erfasst.
- **Verarbeitung:** Nach Upload erscheinen automatisch eine Vorschau und eine AI-Zusammenfassung (folgt).




2. Results

- **Übersicht:** Alle Dokumente werden angezeigt, inkl. Name, Datum, Tags und AI-Zusammenfassung.
- **Suche:** Eingabe in die Suchleiste aktualisiert die Ansicht in Echtzeit.
- **Fuzzy-Toggle:** Erlaubt tolerante Suche (z.B. Tippfehler).
- **Filterfunktion:** Dokumenttypen können per Button ein-/ausgeblendet werden.



3. Manage

- **Dokumente suchen:** Suchfeld und Filter stehen zur Verfügung.
- **Actions:** Dokumente können gelöscht oder aktualisiert werden.



Interaktionen

- **Suche:** Echtzeit-Filterung, Fuzzy-Toggle für Tippfehler-Toleranz.
- **Upload:** Klick auf Select File lädt Beispiel-Dokument, nach Upload erscheinen Preview und Zusammenfassung.

- **Dokumentdetails:** Klick auf ein Ergebnis öffnet die Vorschau. Tabs innerhalb der Vorschau:
 - **Summary:** Editierbar.
 - **Metadaten:** Titel, Autor, Tags editierbar.
 - **Activity Log:** Upload-Datum, Indexierung.

Quarterly Report Q2

Summary

Revenue grew 18% YoY. Key drivers include EMEA expansion and pricing updates. Risks: FX volatility.

Save summary

Metadata

Title
Quarterly Report Q2

Author
Alex Kim

Tags
Finance, Q2

Delete Reprocess OCR Save

Activity

- ✓ Uploaded on 2025-08-14
- ✓ Indexed in ElasticSearch
- ✓ Summary generated

Queues, Worker & Logging (Sprint 3)

Ziele

- Integration von RabbitMQ als Messaging-System.
- API sendet OCR-Nachricht nach Upload.
- OCR-Worker empfängt und loggt Nachrichten (Proof-of-Concept).
- Logging & Fehlertoleranz sicherstellen.
- Keine HTTP-500 bei Messaging-Fehlern.

RabbitMQ-Integration - Technische Dokumentation

Architekturüberblick

Komponente	Rolle
Queue	ocr-queue
Publisher	API (DocumentsController - RabbitMqService)
Consumer	OCR-Worker (Konsolen-App / Container)
Infrastruktur	docker-compose.yml enthält rabbitmq:3-management (Ports 5672, 15672)

Ablauf beim Upload (technisch)

1. Client API

POST /api/documents (multipart/form-data) mit file , title , optional description , tags .

2. Validierung

DocumentsController prüft ModelState bei Fehlern 400 ProblemDetails .

3. Business-Logik

DocumentService.CreateAsync :

- Prüft Titel, Tags.
- Ruft ITagRepository.GetOrCreateAsync auf.
- Erstellt neues Document -Entity.

4. Persistenz (Datenbank)

- IDocumentRepository.AddAsync(doc) - EF Core SaveChangesAsync() .
- Erfolgreiche Speicherung ist Voraussetzung für Queue-Publish.

5. Datei speichern

- Sicherer Name (safeTitle_{DocumentId}.pdf) in files/ gespeichert.

6. Nachricht in RabbitMQ senden

- RabbitMqService.SendOcrMessage(new { DocumentId, FileName }) .
- JSON serialisiert, ocr-queue deklariert, persistent publish.
- Publish-Fehler - **nur Log**, kein HTTP-Fehler.

7. Worker (Consumer)

- Liest ocr-queue .
- Loggt Payload, führt BasicAck aus.
- Proof-of-Concept (keine OCR-Verarbeitung in Sprint 3).

- Später: OCR, Textspeicherung, Folge-Nachrichten.

Logging Levels

Level	Einsatz
Information	Erfolgreiche High-Level Events (Upload, Queue Publish)
Debug	Interne Schritte, z. B. Tag-Auflösung
Warning	Validierungswarnungen, Retry-Themen
Error	Ausnahmefälle, Fehlersituationen

Sprint 4: OCR-Worker, Garage (S3), RabbitMQ

- PDF-Upload landet im **S3-kompatiblen Object Store (Garage)**,
- es wird eine **Nachricht** an **RabbitMQ** gesendet,
- ein **OCR-Worker** verarbeitet die Nachricht, führt OCR via **Ghostscript + Tesseract** aus,
- legt das **Text-Ergebnis (.txt)** wieder im Object Store ab,
- Logging & Fehlverhalten sind nachvollziehbar (Ack/Nack, DLQ).

Architekturüberblick

Client → REST-API → (Garage S3: put PDF) → RabbitMQ: "ocr-queue" → OCR Worker

↓

Garage S3: get PDF → OCR (gs + tesseract) → put

Wesentliche Ziele von Sprint 4

- Separates **Worker-Service** für OCR (eigenes Programm/Container)
- Integration von **Ghostscript** (Rendering) & **Tesseract** (Texterkennung)
- Persistenz der PDFs in **Garage** (S3-kompatibel)
- **Queue-Integration**: Upload triggert OCR asynchron

- Logs, Fehlerbehandlung, optional **Dead-Letter-Queue (DLQ)**

Relevante Komponenten (Code)

1) Message Contract

```
public sealed class OcrJob
{
    public Guid DocumentId { get; init; }
    public string S3Key { get; init; } = null!;
    public string ContentType { get; init; } = "application/pdf";
    public DateTime UploadedAt { get; init; } = DateTime.UtcNow;
}
```

Zweck: Klares Schema für Nachrichten zwischen REST-API und OCR-Worker.

S3Key bestimmt die genaue Position des Dokuments; **DocumentId** für Korrelation/Logs.

2) Publishing (REST-Seite)

```
public class RabbitMqService
{
    // ... ctor mit Host/User/Pass/Queue
    public void SendOcrMessage(object message)
    {
        var json = JsonSerializer.Serialize(message);
        using var connection = _factory.CreateConnection();
        using var channel = connection.CreateModel();

        // Queue passiv prüfen (Topologie wird extern/zu einem anderen Zeitpunkt angelegt)
        try { channel.QueueDeclarePassive(_queueName); }
        catch { /* log warn; wir publizieren trotzdem */ }

        channel.BasicReturn += (_, args) => { /* log unroutable */ };
        var props = channel.CreateBasicProperties();
        props.Persistent = true; // DeliveryMode=2, bei durable Queue restart-fö
        props.ContentType = "application/json";

        channel.BasicPublish(
            exchange: "", // default exchange → routingKey == Queue
            routingKey: _queueName,
            mandatory: true, // löst BasicReturn bei Unzustellbarkeit aus
            basicProperties: props,
            body: Encoding.UTF8.GetBytes(json));
    }
}
```

Wichtig: Persistent=true , mandatory=true , und **JSON** als Austauschformat.

3) OCR-Worker – Options & Bootstrapping

```
public sealed class RabbitOptions
{
    public string Host { get; set; } = "rabbitmq";
    public string User { get; set; } = "guest";
    public string Pass { get; set; } = "guest";
    public string Queue { get; set; } = "ocr-queue";
    public ushort Prefetch { get; set; } = 1;           // Back-pressure
    public bool RequeueOnError { get; set; } = false;  // DLQ freundlich
}

public sealed class GarageS3Options
{
    public string Endpoint { get; set; } = "";          // z. B. http://garage:3900
    public string Region { get; set; } = "garage";      // muss zu garage.toml passen
    public string Bucket { get; set; } = "documents";
    public string AccessKey { get; set; } = "";
    public string SecretKey { get; set; } = "";
}
```

Worker-Start (Program):

- Lädt Konfiguration aus /config/appsettings.json und **ENV**
- Initialisiert **RabbitMQ** (durable Queue, Prefetch, optional DLQ)
- Initialisiert **S3-Client** (Garage): ServiceURL , ForcePathStyle=true , AuthenticationRegion="garage" , UseHttp je nach Endpoint
- Loggt **Ghostscript/Tesseract**-Versionen zur Kontrolle
- Startet asynchronen Konsumenten

4) OCR-Engines (austauschbar)

Interface:

```
public interface IOcrEngine
{
    Task<string> ExtractTextAsync(Stream pdf, CancellationToken ct = default);
}
```

Variante A – CLI (CliOcrEngine):

- `gs` (Ghostscript) rendert PDF → TIFF @ 300 dpi
- `tesseract` extrahiert Text (`-l deu+eng`), Ausgabe `stdout`
- temporäres Arbeitsverzeichnis wird bereinigt

Variante B – Library (OcrEngine):

- **Magick.NET** liest PDF-Seiten @ 300 dpi (Ghostscript zur Laufzeit nötig)
- **Tesseract .NET** verarbeitet die Bilder im Prozess

Vorteil: Austauschbarkeit (Dev/Prod/CI), gute Testbarkeit.

5) Orchestrierung im Worker (OcrJobHandler /Main)

- **Download** PDF aus Garage (S3) → Stream
- **OCR** auf dem Stream → String
- **Upload** Ergebnis als `<key>.txt` (UTF-8, `UseChunkEncoding=false` , `ContentLength` gesetzt)
- **Ack/Nack** der RabbitMQ-Message (bei Fehler optional in DLQ)

Technische Entscheidungen

- **Storage:** Garage (S3) Single-Node, persistente Volumes.
- **S3-Client:** Path-Style, Region „garage“, kein Chunked, `ContentLength` setzen.
- **Message:** OcrJob mit DocumentId + S3Key; Ergebnis als gleiches Key + `.txt`.
- **Publisher (Rabbit):** Default-Exchange, persistent, `mandatory=true`, Topologie nicht erstellen.
- **Worker (Rabbit):** Durable Queue, `Prefetch=1`, manual ack, Fehler → DLQ.
- **OCR:** Ghostscript @300 dpi → Tesseract (eng+deu); Alternative: **Magick.NET** + Tesseract.
- **Config/Logs:** appsettings + ENV Overrides; Versionen von gs/tesseract loggen.
- **Fehler/Resource:** 404 speziell behandeln, Temp-Ordner aufräumen, Streams dispoen.
- **Security:** Secrets über ENV/Docker-Secrets, nicht im Repo.
- **Build:** .NET 8, RabbitMQ.Client 6.6.0, kein Trimming/AOT, Pakete konsistent.

Sicherheit & Betrieb

- **Secrets** (Access/Secret, `rpc_secret`) **nie ins Repo**; via ENV/Docker-Secrets injizieren.
- **Persistenz**: Garage-Volumes für `meta` und `data` mounten; Backups einplanen.
- **TLS**: In Produktion `https://` für Garage und RabbitMQ nutzen.

Nächste Schritte (Folgesprints)

- **Gen-AI Worker**: OCR-Text an LLM → **Zusammenfassung** speichern (Sprint 5)
- **Elasticsearch**: Indexierung des OCR-Textes & Such-Use-Case (Sprint 6)
- **Integrationstests & Batch**: End-to-End Test, XML-Batch für Zugriffsstatistiken (Sprint 7)

Sprint 5: Generative AI-Integration

In Sprint 5 wurde das bestehende Dokumentenmanagementsystem um **Generative AI support** mittels **Google Gemini** erweitert.

Ziel war es, dass nach dem Upload eines Dokuments und der OCR-Verarbeitung automatisch:

1. der extrahierte Text an den GenAI-Dienst (Google Gemini) gesendet wird,
2. ein automatisch generiertes **Summary** zurückkommt,
3. dieses Summary in der **Datenbank** gespeichert wird und
4. über **REST-API** und **UI** verfügbar ist.


Zusätzlich wurden in diesem Sprint Logging, Fehlerbehandlung sowie Docker-Integration für alle neuen Komponenten ergänzt.

Umfang

- Erweiterung von `docker-compose.yml` um den neuen **GenAI-Worker-Service**
- Neues Projekt: `DocumentManagementSystem.GenAI_Worker`
- Erweiterung der **Dokumenten-Verarbeitungskette**:
 - Dokument-Upload
 - Speicherung in Garage (S3-kompatibel)
 - OCR-Worker extrahiert Text

- GenAI-Worker sendet OCR-Text an **Google Gemini**
- Das generierte Summary wird in der Datenbank gespeichert
- Erweiterung der **REST-API**:
 - Summary wird im Document-DTO zurückgegeben
 - Endpoint zum Aktualisieren von Metadaten (Titel, Tags, Summary)
- Integration von **Serilog** für strukturiertes Logging
- Verbesserte **Fehlerbehandlung** bei:
 - Externen API-Fehlern (Gemini)
 - Datenbankzugriffen
 - S3-Kommunikation
 - Worker-Prozessen

Architektur



Komponenten

DocumentManagementSystem.API

- [ASP.NET](#) Core REST API
- Funktionen:
 - Dokument-Upload
 - Auflisten von Dokumenten
 - Aktualisieren von Metadaten (Titel, Tags, Summary)
 - Bulk-Löschen
- Summary wird im Document-DTO ausgegeben.

OCR_Worker

- Konsumiert Nachrichten aus RabbitMQ (ocr-queue)
- Lädt Dokumente aus Garage (S3)
- Führt OCR auf PDF/PNG/JPG durch
- Speichert extrahierten Text in der Datenbank
- Markiert Dokumente als *OCR abgeschlossen*

GenAI_Worker (DocumentManagementSystem.GenAI_Worker)

- **Neuer Worker in Sprint 5**
- Periodisches Polling der Datenbank:
 - Dokumente mit OCR-Text
 - aber ohne Summary
- Sendet den Text an **Google Gemini**
- Speichert die generierte Zusammenfassung in der Datenbank

UI – React / Vite / Tailwind

- Neues Panel für „**AI Summary**“
- Editierbare Felder für:
 - Titel
 - Tags
 - AI-Zusammenfassung
- Unterstützt Bulk-Aktionen wie Sammellöschen

Infrastruktur

- PostgreSQL

- RabbitMQ
- Garage (S3-kompatibel)
- Docker Compose für Orchestrierung

GenAI-Integration / Google Gemini

Konfiguration

Konfiguration erfolgt über `appsettings.json` (ohne Secrets) und Umgebungsvariablen.

`appsettings.json` (Auszug)

```
"Gemini": {  
  "ApiKey": "",  
  "BaseUrl": "https://generativelanguage.googleapis.com/v1beta",  
  "Model": "models/gemini-2.5-flash"  
}
```

Sprint 6 - ELK, Use Cases

Architektur / Verarbeitungspipeline

1. Upload

- `DocumentService.CreateAsync(...)` speichert:
 - Dokument-Metadaten in PostgreSQL
 - PDF nach Garage S3 als `{DocumentId}.pdf`
- OCR Queue ist in deinem aktuellen Code teilweise auskommentiert (`CreateAsync` enthält einen auskommentierten MQ-Teil).

2. OCR

- OCR schreibt Ergebnis in `Documents.OcrText` (und optional `OcrCompletedAt`)

3. GenAI Worker (Gemini)

- Worker zieht „fällige“ Dokumente aus der DB:
 - `OcrText != null`

- Summary/Metadata/Embedding fehlt
- Retry-Backoff beachtet (`AiNextAttemptAt` , `AiAttempts`)
- Schritte:
 - a. Summary erzeugen (`GenerateSummaryAsync`)
 - b. Metadata + Entities extrahieren (`ExtractMetadataAsync`)
 - c. Auto-Tags hinzufügen (`AddTagIfMissingAsync`)
 - d. Embedding erzeugen (`GenerateEmbeddingAsync`)
- Wenn alles fertig:
 - `AiProcessedAt` gesetzt

4. Elasticsearch Indexing (einmalig)

- Wenn `AiProcessedAt != null` und `IndexedAt == null` :
 - `doc.ToDocumentIndex()`
 - `IndexDocumentAsync(...)`
 - `IndexedAt` wird gesetzt

Elasticsearch

Index Model (`DocumentIndex`)

Index: `documents`

Felder:

- `Id` (`Document.Id` als String)
- `Title`
- `Content` = OCR Text (`OcrText`)
- `Summary`
- `Tags` (Tag-Namen)
- `UploadedAt` (`CreatedAt`)

Mapping passiert hier:

- `DocumentIndexMapper.ToDocumentIndex(Document document)`

Indexing passiert hier:

- `SearchIndexService.IndexDocumentAsync(...)`

Unique Feature

1) Automatische Metadatenextraktion (KI)

Aus `OcrText` wird automatisch extrahiert und in `DocumentMetadata` gespeichert:
z.B.:

- Dokumenttyp: INVOICE | CONTRACT | REMINDER | OTHER
- IssueDate (DateOnly?)
- InvoiceNumber
- Iban
- RawJson (für Debugging)

Wozu?

- Dokumente sind sofort strukturiert (Filter/Anzeige ohne manuelle Eingabe)

2) Entities (Personen/Firmen/Orte)

KI extrahiert Listen und speichert sie in `ExtractedEntities` :

- Type : PERSON / ORG / LOCATION
- Value : erkannter Wert

Wozu?

- Du kannst später nach Firma/Person/Ort filtern oder im UI anzeigen

3) Intelligentes Auto-Tagging

Basierend auf Metadaten/Entities/Keywords werden Tags automatisch ergänzt:

- `type:INVOICE`
- `year:2025`
- `Q1-2025`
- `org:<name>`
- `kw:<keyword>`

Wozu?

- Einheitliche Tags ohne manuelles Tippen
- Schnelles Filtern in der UI

4) Embeddings

Für jedes Dokument wird ein Embedding erstellt und in `DocumentEmbedding` gespeichert:

- `Model`
- `Dims`
- `VectorJson`

Wozu?

- Basis für “Ähnliche Dokumente” / semantische Suche (auch wenn Wörter unterschiedlich sind)

Datenbank-Status

Tabelle `Documents` enthält u.a.:

- `Title` , `Description` , `CreatedAt` , `UpdatedAt`
- `OcrText` , `OcrCompletedAt`
- `Summary` , `AIProcessedAt`
- `IndexedAt`
- Backoff/Retry: `AINextAttemptAt` , `AIAttempts` , `AILastError`

Neue Tabellen:

- `DocumentMetadatas` (1:1)
- `ExtractedEntities` (1:n)
- `DocumentEmbeddings` (1:1)
- `Tags` + Join Tabelle `DocumentTag`

API DTO Output

`DocumentResponseDto` enthält:

- `OcrText` , `Summary`
- `Metadata` (`DocumentMetadataDto`)
- `Entities` (`ExtractedEntityDto`)

- `Embedding ( DocumentEmbeddingDto )`

Damit ist euer Unique Feature direkt sichtbar in der API Response.

Sprint 7: Integrationstests & Batch-Processing

In der finalen Phase wurde das System um automatisierte Qualitätskontrollen und eine Schnittstelle für externe Statistikdaten erweitert.

1. Integration-Tests (End-to-End)

Um die korrekte Funktion der gesamten Kette sicherzustellen, wurde ein Integration-Test für den Use-Case "**Document Upload**" implementiert.

- **Test-Ablauf:**
 - i. Simulation eines Datei-Uploads über die REST-API.
 - ii. Validierung der Persistenz in der **PostgreSQL** Datenbank.
 - iii. Prüfung der Speicherung im **Garage S3** Object Store.
 - iv. Verifizierung, dass eine Nachricht an die **RabbitMQ** Queue gesendet wurde.
- **Ausführung:**

```
dotnet test DocumentManagementSystem.Tests
```

2. Batch-Processing Service (Daily Access Logs)

Ein neuer, zeitgesteuerter Dienst wurde integriert, um Zugriffszahlen aus externen Systemen via XML-Dateien zu importieren.

- **Funktionsweise:**
 - Der Dienst scannt ein konfigurierbares Eingangsverzeichnis nach neuen XML-Dateien.
 - Extraktion der Zugriffsdaten pro Dokument-ID.
 - Aktualisierung der `DailyAccessCount` in der PostgreSQL Datenbank.
 - Erfolgreich verarbeitete Dateien werden in einen Archiv-Ordner verschoben, um doppelte Verarbeitungen zu verhindern.
- **Zeitsteuerung:** Der Prozess ist standardmäßig so konfiguriert, dass er täglich um **01:00 Uhr** ausgeführt wird.

Beispiel für das XML-Format (access_log.xml):

```
<AccessStatistics date="2026-01-25">
  <Entry>
    <DocumentId>550e8400-e29b-41d4-a716-446655440000</DocumentId>
    <AccessCount>42</AccessCount>
  </Entry>
  <Entry>
    <DocumentId>6ba7b810-9dad-11d1-80b4-00c04fd430c8</DocumentId>
    <AccessCount>15</AccessCount>
  </Entry>
</AccessStatistics>
```

Finalisierung & Code-Review Vorbereitung

Das Projekt erfüllt alle Kriterien der Sprints 1 bis 7:

- Unit Tests & Coverage: Abdeckung der Business-Logik und Worker-Dienste (> 70%).
- Logging & Error Handling: Durchgängige Implementierung von Layer-spezifischen Exceptions und strukturiertem Logging.
- Containerisierung: Alle Dienste (API, UI, OCR-Worker, GenAI-Worker, Elasticsearch, RabbitMQ, DB, Garage) sind in der docker-compose.yml orchestriert.

HOWTO: System-Validierung

1. Starte das System via `docker compose up -d`.
2. Lade eine PDF-Datei (`HelloWorld.pdf`) über das Frontend hoch.
3. Prüfe in der UI, ob die KI-Zusammenfassung erscheint.
4. Suche nach dem Begriff "Hello", um die Elasticsearch-Indizierung zu bestätigen.
5. Lege eine XML-Testdatei in den konfigurierten Batch-Ordner, um die Statistik-Aktualisierung zu triggern.