

Unique Feature – Dokumentenmanagementsystem (Vorschlag)

Für unser Dokumentenmanagementsystem planen wir ein **Unique Feature**, das über die Basisfunktionalität eines klassischen DMS hinausgeht. Wir möchten OCR-Texterkennung mit generativer KI (Google Gemini) und semantischer Vektorsuche kombinieren, um die Dokumentenverwaltung intelligent zu automatisieren.

Unser geplantes Unique Feature

Unser System soll drei zentrale Funktionen bieten, die über Standard-DMS hinausgehen:

1. Automatische Metadatenextraktion mit KI

Nach dem Upload und der OCR-Verarbeitung soll ein GenAI-Worker den Text automatisch mit **Google Gemini** analysieren und strukturiert extrahieren:

- Personen, Unternehmen, Orte
- Datums- und ID-Angaben (Rechnungs-Nr., IBAN, etc.)
- Dokumenttyp (Rechnung, Vertrag, Mahnung, etc.)
- Relevante Keywords

Vorteil: Keine manuelle Metadateneingabe nötig, konsistente Datenstruktur, sofort durchsuchbar.

2. Intelligentes, automatisches Tagging

Basierend auf den KI-extrahierten Metadaten soll das System automatisch strukturierte Tags generieren:

- Dokumenttyp: „Rechnung“, „Vertrag“
- Zeitkontext: „2025“, „Q1-2025“
- Organisationen: „Firma XY“
- Thematik: „Finanzwesen“, „Personal“

Vorteil: Sofortige Kategorisierung, einheitliche Taxonomie, flexible Filter- und Suchfunktionen.

3. Semantische Ähnlichkeitserkennung

Das System soll für jedes Dokument **Embedding-Vektoren** (numerische Repräsentation des Inhalts) erzeugen und damit semantischen Vergleich statt nur Keyword-Suche ermöglichen.

Das System würde automatisch erkennen:

- Thematisch ähnliche Dokumente
- Inhaltliche Zusammenhänge (z. B. Angebot → Auftrag → Rechnung)
- Semantische Ähnlichkeit trotz unterschiedlicher Formulierungen

Im UI soll ein „**Ähnliche Dokumente**“-Bereich angezeigt werden mit Vorschau, Matching-Score und Direktlinks.

Vorteil: Kontexterkennung, Duplikaterkennung, intelligente Empfehlungen, bessere Navigation.

Geplante technische Umsetzung

Architektur

Upload → OCR (Tesseract) → GenAI Worker (Google Gemini) →
→ Metadaten + Tags + Embeddings →
→ Indexing Worker (Elasticsearch) →
→ UI (React)

Geplante Verarbeitungspipeline

1. Upload → Speicherung in S3
2. OCR-Worker extrahiert Text (RabbitMQ Queue)
3. **GenAI-Worker analysiert Text mit Gemini** (Metadaten + Tags + Embeddings) → **NEU**
4. **Indexing-Worker überträgt zu Elasticsearch** → **NEU**
5. **UI zeigt Metadaten, Tags und ähnliche Dokumente an** → **NEU**

Abgrenzung zu Standard-DMS

Standard-DMS:

- Manuelles Tagging
- Nur Keyword-Suche
- Statische Metadaten
- Keine inhaltliche Analyse

Unser geplantes System:

- Vollautomatische Metadatenextraktion mit KI
- Intelligentes, kontextbezogenes Tagging
- Semantische Ähnlichkeitssuche
- Inhaltsbasierte Dokumentenverknüpfung
- Skalierbare, asynchrone Verarbeitung